

# 一种改进的图卷积网络半监督节点分类

薛磊<sup>1</sup> 农丽萍<sup>2,3</sup> 张文辉<sup>1\*</sup> 林基明<sup>1,2</sup> 王俊义<sup>1</sup>

<sup>1</sup>( 桂林电子科技大学信息与通信学院 广西 桂林 541004)

<sup>2</sup>( 西安电子科技大学通信工程学院 陕西 西安 710071)

<sup>3</sup>( 广西师范大学物理科学与技术学院 广西 桂林 541004)

**摘要** 目前大多数图卷积(GCN)关注于提取局部特征信息,忽略了全局特征,使得标签不能有效地传播到整个图上。对此,设计一种可以用于半监督节点分类任务的深度池化对偶图神经网络(DPDNN)。该网络引入池化机制,将结构相似的节点聚合为超节点,扩大节点的接收域。通过随机游走得到图全局信息的潜在表示,使用随机游走模型与GCN进行协同训练,从而补充GCN模型在获取整个图拓扑结构信息上的能力。实验结果表明,该网络模型与现有方法相比提高了分类精度,在少量数据标记时效果更为明显。

**关键词** 图卷积网络 图信号 图池化 半监督学习

中图分类号 TP3 文献标志码 A DOI: 10.3969/j.issn.1000-386x.2021.10.023

## AN IMPROVED GRAPH CONVOLUTION NETWORK SEMI-SUPERVISED NODE CLASSIFICATION

Xue Lei<sup>1</sup> Nong Liping<sup>2,3</sup> Zhang Wenhui<sup>1\*</sup> Lin Jiming<sup>1,2</sup> Wang Junyi<sup>1</sup>

<sup>1</sup>( School of Information and Communication, Guilin University of Electronic Technology, Guilin 541004, Guangxi, China)

<sup>2</sup>( School of Telecommunication Engineering, Xidian University, Xi'an 710071, Shaanxi, China)

<sup>3</sup>( College of Physics and Technology, Guangxi Normal University, Guilin 541004, Guangxi, China)

**Abstract** At present, most graph convolution(GCN) focuses on extracting local feature information while ignoring global features, so that tags cannot be effectively propagated to the entire graph. This paper designed a deep pooled dual graph neural network(DPDNN) that can be used for semi-supervised node classification tasks. This network introduced a pooling mechanism to aggregate nodes with similar structures into super nodes and expand the receiving field of each node. Through random walk, DPDNN obtained the potential representation of the global information of the graph, and by using the random walk model to coordinate training with GCN, the ability of the GCN model to acquire the whole graph topology information was supplemented. The experimental results show that compared with the existing methods, this network model improves the classification accuracy, and the effect is more obvious in a small amount of data markers.

**Keywords** Graph convolutional network Graph signal Graph pooling Semi-supervised learning

## 0 引言

近年来,深度学习在越来越多的领域取得了显著的成绩,特别是在语音识别<sup>[1]</sup>、自然语言处理和计算机

视觉<sup>[2]</sup>等领域。深度学习在欧几里得数据上取得了巨大的成功,但是越来越多的应用需要对非欧几里得数据如图或流形进行分析。例如,在电子商务中,一个基于图的学习系统能够利用用户与商品之间的交互做出推荐;在化学中,需要识别被建模为图结构的分子的生

收稿日期:2019-11-19。国家自然科学基金项目(61966007);“认知无线电与信息处理”省部共建教育部重点实验室基金项目(CRKL180201,CRKL180106)。薛磊,硕士生,主研领域:图卷积神经网络,几何深度学习。农丽萍,博士生。张文辉,副教授。林基明,教授。王俊义,研究员。

(C)1994-2021 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

物活性以发现新药物;在引文网络中,论文需要通过被引用的关系相互连接,然后通过挖掘关系被分成不同的组。挖掘这些图结构数据隐含的信息,成为当今学者研究的热门话题。

众所周知,深度学习模型一般需要大量的标记数据,但标记训练数据的代价很大。为了减少用于标记训练数据的数据,半监督学习开始兴起,它旨在从每个类只有很少的样本中学习一个分类模型。图结构数据分布不规则,且每个节点有不同数量的近邻节点,一些重要的操作,如卷积适用于规则结构数据(图片和视频),但是不适用于图结构数据。此外,现有的深度学习算法假设数据之间是相互独立的,但是图结构数据中每个数据节点都通过一些引用、交互等依赖关系与其近邻节点相关联。可见图结构数据的复杂性和标记训练数据的代价给现有的深度学习算法带来了巨大的挑战。最早尝试将神经网络推广到图是 Gori<sup>[3]</sup>和 Scarselli<sup>[4]</sup>等,主要通过迭代的方式,利用循环神经网络传播近邻节点信息,聚合到一个稳定的不动点,来学习目标节点的表示。然而这种方法在当时几乎没有引起注意,直到最近才被重新发现<sup>[5-6]</sup>。2013年,Bruna等<sup>[7]</sup>首次将谱图理论和深度学习的思想结合起来,提出了图卷积神经网络(GCN)的方法,使用了谱域中卷积的定义。该方法虽然具有概念上的重要性,却带来了显著的计算缺陷,使得这些方法达不到真正有用。Defferrard等<sup>[8]</sup>提出了一种有效的滤波方案,通过使用K阶近似的切比雪夫多项式来显式计算拉普拉斯特征向量,该网络训练效率低,并且计算复杂度高。Kipf等<sup>[9]</sup>采用近似一阶频谱图卷积的方法,直接在图结构数据的模型上进行操作,提出一种简单高效的传播模型,能够处理节点的半监督分类问题,但是由于模型较浅不能捕获图的全局结构信息,也会遇到卷积核局部性等问题。Perozzi等<sup>[10]</sup>和 Grover等<sup>[11]</sup>以无监督的方式通过随机游走将图节点用低维、连续的向量表示,但无法利用图结构数据的属性信息,也不能以端对端的方式执行节点分类任务。JK-Nets<sup>[12]</sup>通过层次聚合机制来组合每个图卷积网络的输出表示,但是它只能跨图的边缘传播信息,而不能按层次汇总信息,无法学习图的层次结构。对此,Ying等<sup>[13]</sup>提出一个用于图嵌入的池化层 DiffPool,以通过可区分的网络来减小尺寸,由于 DiffPool 是为图分类任务而设计,因此无法为图中的每个节点生成嵌入,不能直接应用于节点分类任务。Ioannidis等<sup>[14]</sup>等借鉴一阶频谱图卷积的思想,提出在每一层的输入采用一种递归的数据馈送,促进了图中的特征扩散,但传播效率不高。Li等<sup>[15]</sup>采用半监督的方式通过随机游走简单混合了节点邻域的属性,

有效地将标签数据传播到整个图上,但学习过程中导致图结构信息丢失,结果精确度不高。Jiang等<sup>[16]</sup>提出图优化神经网络,将图优化和图卷积进行正则化结合,通过学习调整图结构来获得更好的图嵌入节点表示,取得了不错的效果。

针对以上问题,本文设计了深度池化对偶图神经网络,主要工作概括如下:(1)在图卷积神经网络引入图池化机制加深了模型层数,将结构相似的点聚合为超节点,扩大节点的接收域;(2)使用随机游走模型获得节点全局信息,与GCN进行协同训练,解决了卷积核局部性问题,扩大了局部特征信息,利用局部信息和全局信息进行特征提取;(3)在公开数据集Cora、Citeseer、Pubmed上进行了实验,与多种类型的算法进行对比,在少量数据标记时能更好地将数据标签传播到图上,从而提取更深层次的特征,提高数据集的分类精确度。

## 1 深度池化对偶图神经网络

本文模型主要分为三步:(1)利用图的邻接矩阵和特征输入构建深度池化神经网络;(2)构建基于随机游走的卷积神经网络;(3)将二者结合进行协同训练。

半监督学习<sup>[17]</sup>考虑了从标记数据和无标记数据中学习的一般问题。本文将复杂网络抽象为图,对于给定的图 $G=(V,E,W)$ 模型,其中: $V=\{v_i, i=1,2,\dots,n\}$ 表示顶点集合; $E=\{e_i, i=1,2,\dots,m\}$ 表示边集合,且 $(v_i, v_j) \in E$ 表示网络中的关系; $W \in \mathbf{R}^{N \times N}$ 表示图的邻接权重矩阵。对于每个图存在邻接矩阵 $A$ ,节点 $A_{ij}$ 有连边时值为1,否则为0。图中每一个节点对应一个标签,对于所有节点 $N$ 的标签 $y_N \in \{0,1,\dots,k-1\}$ ,半监督学习的目的是预测无标记节点的标签。

### 1.1 图卷积神经网络

图卷积神经网络(GCN)在网络节点分类任务中有很好的泛化效果,本文工作是在文献[9]的基础上做的。给定输入特征矩阵 $X$ 和邻接矩阵 $A$ ,GCN的传播规则如下:

$$\text{Conv}_A^i(X) = G_i = \sigma(\tilde{D}_i^{-1/2} \tilde{A}_i \tilde{D}_i^{-1/2} H_{i-1} W_i) \quad (1)$$

式中:第 $i$ 层网络的输入为 $H_i \in \mathbf{R}^{N \times D}$ (初始输入为 $H_0 = X$ ) $N$ 为图中的节点数量,每个节点使用 $D$ 维特征向量进行表示; $\tilde{A} = A + I_N$ 为添加了自连接的邻接矩阵; $\tilde{D}$ 为度矩阵, $\tilde{D}_{i,i} = \sum_j \tilde{A}_{i,j}$ ;  $W_i \in \mathbf{R}^{D \times D}$ 为待训练的参数; $\sigma$ 为相应的激活函数,例如 $\text{ReLU}(\cdot) = \max(0, \cdot)$ 。

## 1.2 图池化和细化

图的池化就是将结构相似节点聚合在一起,相当于保留局部几何多尺度结构。图的细化目的是为了恢复节点的拓扑结构,方便进行节点分类。每个池化层包括图卷积和图池化两个步骤。首先用式(1)进行邻域信息的聚集来提取结构特征和属性特征,再通过结构等效分组和结构相似分组。

1) 结构等效分组。如果两个节点共享同一组邻居,则它们在结构上是等效的。然后将这两个节点分配为超节点。如图1所示,节点B和D在结构上是等效的,因此将这两个节点分配为超节点。对这些在结构上等效的节点进行标记,保留其他未分组没有标记的节点,以避免在节点上重复进行分组操作。

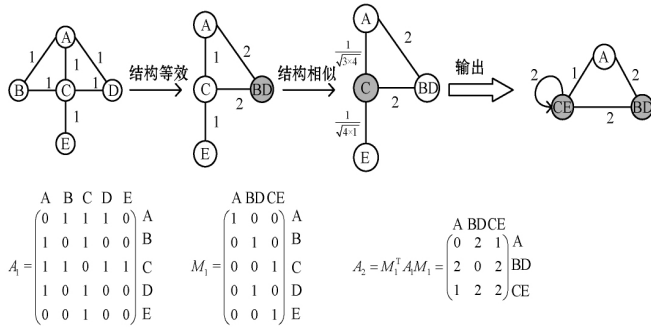


图1 图池化操作

2) 结构相似分组。在未标记的节点对  $(v_j, v_k)$  之间进行结构相似性计算作为归一化连接权重  $s(v_j, v_k)$ , 计算公式如下:

$$s(v_j, v_k) = \frac{A_{jk}}{\sqrt{D(v_j) \cdot D(v_k)}} \quad (2)$$

式中:  $A_{jk}$  是节点对  $(v_j, v_k)$  的边权重;  $D(\cdot)$  是节点的度。在进行结构相似分组时, 迭代取出未标记的节点  $v_j$ , 并计算与其所有未标记的邻居节点  $v_k$  的归一化连接权重, 之后选择结构相似度最大的邻居节点形成一个新的超级节点并标记这两个节点。如果一个节点未标记, 而其他所有邻居节点都被标记, 那么它也将被标记, 并独自构成一个超节点。例如, 在图1中, 节点对  $(C, E)$  具有最大的结构相似性, 因此将它们组合在一起以形成一个超节点。由于仅节点A没有标记, 其他邻居节点都被标记, 所以本身构成了一个超节点。

为了恢复原有节点的拓扑结构, 方便进行节点分类, 在矩阵  $M_i$  中保留了节点及其对应的超节点之间的分组关系。在第  $i$  层, 分组矩阵  $M_i$  中的  $m_{jk}$  计算方式为:

$$m_{jk} = \begin{cases} 1 & G_i \text{ 中的节点被分到超节点中} \\ 0 & \text{其他} \end{cases} \quad (3)$$

在图1中, 以节点B、D为例, 由于节点B、D在超节点BD中, 其对应的  $m_{1,4}$  和  $m_{3,4}$  值为1。

下一层的池化特征矩阵  $H_{i+1}$  和邻接矩阵  $A_{i+1}$  计算为:

$$\begin{aligned} H_{i+1} &= M_i^T \cdot G_i \\ A_{i+1} &= M_i^T A_i M_i \end{aligned} \quad (4)$$

池化图  $G_{i+1}$  及特征表示矩阵  $H_{i+1}$  将会作为下一层神经网络的输入, 图池化过程具体步骤如下:

输入: 图  $G_i$  和节点特征表示  $H_i$ 。

输出: 池化图  $G_{i+1}$  和池化节点特征表示  $H_{i+1}$ 。

- (1) 根据式(1)计算 GCN 的输出  $G_i$ ;
- (2) 计算结构等效分组;
- (3) 根据式(2)进行结构相似分组;
- (4) 更新节点权重和边权重;
- (5) 根据式(3)保留超节点分组关系;
- (6) 根据式(4)计算特征矩阵  $H_{i+1}$  和池化图  $G_{i+1}$ 。

3) 图的细化层。为了恢复图的原始拓扑结构进一步促进节点分类, 恢复与池化层相同数量的细化层, 然后经过短连接, 与图池化层一样也分为两步: 节点的嵌入, 恢复节点表示。节点的分层表示主要是通过 GCN, 由于在池化过程中将分组关系保存在分组矩阵中, 因此利用  $M_{l-i}$  恢复第  $i$  层的细化节点表示矩阵, 恢复节点的表示计算方式如下:

$$H_i = M_{l-i} \cdot G_i + G_{l-i} \quad (5)$$

如图2所示, 深度池化神经网络主要由池化层和细化层组成。对于每个池化层, 首先进行图卷积运算以学习节点表示; 然后, 执行池化操作以结构相似的节点聚合为超节点。池化操作后, 每个超节点有了更大的接收域, 这有利于捕获节点信息。在池化层之后, 运用对称图细化层以恢复用于节点分类任务的原始图结构, 将池化层和细化层进行短连接, 最后经过 Softmax 分类器进行分类。这样分层模型可以从局部到全局的角度全面捕获节点的信息, 从而更好地表示节点。




图2 深度池化神经网络

## 1.3 基于随机游走的卷积神经网络

除了由邻接矩阵  $A$  得到的图结构信息之外, 本文进一步计算正点态互信息矩阵, 得到图全局相关信息的潜在表示, 该信息矩阵被表示为  $P \in \mathbf{R}^{n \times n}$ , 与邻接矩

阵有相似的结构。首先利用随机游走来计算频率矩阵  $F$  在  $F$  基础上计算  $P$ 。最后,本文设计了基于随机游走的卷积神经网络  $ConvP$ 。

计算频率矩阵的步骤如下:

- (1) 输入邻接矩阵  $A$ , 随机游走长度  $l$ , 采样次数  $w$ ;
- (2) 初始化频率矩阵  $F$ ;
- (3) 记录每个节点  $x_i$  的邻居节点  $c_j$ ;
- (4) 遍历每个节点依次把遍历的节点作为根节点;
- (5) 选取根节点  $x_i$  到随机游走长度  $l$  的节点路径  $S$ ;
- (6) 均匀采样  $w$  次经过路径  $S$  中的节点对  $(x_i, c_j)$ ;
- (7) 计算频率矩阵  $F$ , 即采样到的节点对  $(x_i, c_j)$ ,  $\sum F_{ij} = 1$ 。

计算 PPMI。在频率矩阵  $F$  中, 行向量  $F_{i,:}$  表示  $F$  矩阵中的第  $i$  行; 列向量  $F_{:,j}$  表示  $F$  矩阵中的第  $j$  列。 $F_{i,:}$  对应节点  $x_i$ ,  $F_{:,j}$  表示对应节点的近邻点  $c_j$ 。 $F_{i,:}$  的值表示  $x_i$  与  $c_j$  采样的频率, 基于  $F$ , 本文计算出矩阵  $P \in \mathbf{R}^{n \times n}$ :

$$\begin{aligned} P_{ij} &= \frac{F_{ij}}{\sum_j F_{ij}} \\ P_{i*} &= \frac{\sum_j F_{ij}}{\sum_j F_{i*}} \\ P_{*j} &= \frac{\sum_i F_{ij}}{\sum_i F_{*j}} \\ P_{ij} &= \max \left\{ pmi_{ij} = \log \left( \frac{P_{ij}}{P_{i*} P_{*j}} \right) \right\} \end{aligned} \quad (6)$$

式中:  $P_{ij}$  表示节点  $x_i$  与  $c_j$  的估计概率;  $P_{i*}$  是节点  $x_i$  的估计概率,  $P_{*j}$  是  $c_j$  的估计概率。PPMI 主要用来编码语义特征信息, 已经在自然语言处理获得广泛的研究, 并在相似性任务<sup>[18]</sup>上得到很好的效果, 可以衡量两个变量的相关性, 在本文中主要用随机游走的方式计算节点多跳之间的关联度, 能获取全局特征信息。

PPMI 卷积。  $P$  卷积和上节由邻接矩阵给出的  $ConvA$  卷积类似, 本文给出下面的定义:

$$Conv_P^i(X) = G_i = \sigma(D_i^{-1/2} P D_i^{-1/2} H_{i-1} W_i) \quad (7)$$

式中:  $P$  为 PPMI 矩阵;  $D_{i,i} = \sum_j P_{ij}$ 。显然, 基于这种节点邻近的矩阵  $P$  的扩散能获得全局信息, 此外, 通过使用与  $ConvA$  相似的神经网络结构, 可以非常简洁

地将两者结合在一起。本文采用随机游走卷积神经网络优点如下: (1) 能够将标记的数据有效的传播到整个图上, 解决卷积核局部性问题。(2)  $P$  矩阵在不同数据点之间形成了更多的潜在关系, 是邻接矩阵另一种形式的表示。

#### 1.4 深度池化和随机游走协同训练

深度池化神经网络通过池化操作加深了图卷积神经网络模型, 将结构相似的节点聚集在一起形成超节点, 丰富了节点的信息, 而卷积核局部性问题则通过随机游走网络模型得到解决。为了实现二者的协同训练以更好地互补, 提出将  $ConvA$  和  $ConvP$  进行集成学习。本文使用有标签的数据来训练  $ConvA$ , 得到监督损失  $L_0(ConvA)$ , 通过训练  $P$  来得到无监督正则化损失  $L_{reg}(ConvA, ConvP)$ 。

计算损失函数。假设数据集有  $c$  类标签, 经过  $ConvA$  全连接层后的输出为  $Z^A \in \mathbf{R}^{n \times c}$ , 之后经过 Softmax 层输出为  $\hat{Z}^A \in \mathbf{R}^{n \times c}$ ,  $ConvA$  的损失函数为:

$$Loss = - \sum_{f \in y_L} \sum_{i=1}^c Y_{fi} \ln \hat{Z}_{fi}^A + \lambda(t) \frac{1}{n} \sum_{f=1}^n \|\hat{Z}_{f*}^P - \hat{Z}_{f*}^A\|^2 \quad (8)$$

式中: 第一项为交叉熵损失,  $y_L$  表示标签节点集合,  $Y_{fi}$  表示标签矩阵; 第二项为正则化项, 类似于  $ConvA$ 。在经过 Softmax 层输出后,  $ConvP$  的输出结果为  $\hat{Z}^P \in \mathbf{R}^{n \times c}$ , 在训练所有的数据点后, 引入了无监督的损失函数, 该函数最小化了  $\hat{Z}^P$  和  $\hat{Z}^A$  之间的均方误差。

算法 1 描述了本文的对偶图卷积网络方法的训练过程, 图 3 所示为本文对偶图递归神经网络框架。损失函数定义为  $L_0(ConvA)$  和  $L_{reg}(ConvA, ConvP)$  的加权和。本文使用动态权重函数  $\lambda(t)$  来实现上述联合。在训练过程开始时, 损失函数主要由监督项  $L_0$  支配。在使用  $ConvA$  获得标签上的后验分布后, 改变  $\lambda(t)$  来同时考虑  $ConvP$  神经网络, 通过协同训练来提高精确度。

##### 算法 1 深度池化对偶神经网络

输入: 特征矩阵  $X$ , 标签矩阵  $Y$ , 扩散矩阵  $A$  和  $P$ 。

输出: 训练模型, 半监督分类精度。

1. 构建网络时随机初始化  $W^{(1)}, W^{(2)}, \dots, W^{(h)}$
2. 随机初始化动态权重函数  $\lambda(t)$
3. for  $i$  in range  $[0, \text{num\_of\_epochs}]$  do
4.  $\hat{Z}^A \leftarrow \text{softmax}(ConvA(X))$   $\triangleright$  式(1)
5.  $\hat{Z}^P \leftarrow \text{softmax}(ConvP(X))$   $\triangleright$  式(7)
6.  $loss \leftarrow L_0(\hat{Z}^A) + \lambda(t) L_{reg}(\hat{Z}^A, \hat{Z}^P)$   $\triangleright$  式(8)
7. 使用  $\frac{\partial loss}{\partial W^{(1)}}, \frac{\partial loss}{\partial W^{(2)}}, \dots, \frac{\partial loss}{\partial W^{(h)}}$  更新  $W$ ,  $\frac{\partial loss}{\partial \lambda(t)}$  更新  $\lambda(t)$
8. if 结果收敛 then

9. break loop  
10. end if  
11. end for




图 3 深度池化对偶图网络框架

2 实验

2.1 实验数据及设置

为了验证本文方法的有效性,与文献[9]一样,本文采用了三个引文网络的数据集 Cora、Citeseer、Pubmed,其中节点表示论文,节点的特征描述该论文的词袋表示,边表示论文的引用关系。表 1 详细描述了三个数据集。

表 1 本研究采用的数据集统计信息

数据集	节点总数	特征数量	类数	训练节点	验证节点	测试节点
Cora	2 708	1 433	7	140	500	1 000
Citeseer	3 327	3 703	6	120	500	1 000
Pubmed	19 717	500	5	60	500	1 000

实验采用算法 1 所示的网络模型进行训练,对于实验数据集的设置,引文网络中每个文档都有一类标签,每个数据集选用每类主题中的 20 个标签进行训练,随机选择 500 个节点作为验证集,1 000 个节点作为测试集。

实验的硬件环境为英特尔 Xeon E5-2698 处理器、16 GB 显存和 128 GB 运行内存;软件环境为 Ubuntu 18.04 X64 操作系统、CUDA10、TensorFlow 1.14 和 Python 3.7。

2.2 准确性分析

为了验证本文方法的准确性,本文采用引文网络数据集进行实验,超参数设置主要有:dropout 0.90,L2 正则化的权重衰减系数为  $7 \times 10^{-4}$ ,学习率为 0.03,隐藏单元数为 32,使用 dropout 和 L2 归一化的目的是防止训练时过拟合。三个引文网络数据集的池化卷积层数都为 4,最后使用一个全连接层用于节点分类和预测。在训练过程中,采用 Adam 优化器进行优化,得到测试结果的分类精度对比结果如表 2 所示。

表 2 引文网络数据集的分类准确性对比(%)

方法	Citeseer	Cora	Pubmed
DeepWalk <sup>[10]</sup>	43.2	67.2	65.3
LP <sup>[20]</sup>	45.3	68.0	63.0
Planetoid <sup>[19]</sup>	64.7	75.7	77.2
GCN <sup>[9]</sup>	70.3	81.5	79.0
GRNN <sup>[14]</sup>	70.8	82.8	79.5
GOCN <sup>[16]</sup>	71.8	84.8	79.7
DPDNN	73.3	84.3	80.2

实验结果验证了本文提出的关于随机游走的卷积神经网络进行协同训练能够弥补 GCN 的不足。传统的基于随机游走算法如 DeepWalk 和 Planetoid,它们的性能相对较差,原因在于:DeepWalk 无法对属性信息进行建模;Planetoid<sup>[19]</sup>在随机抽样过程中存在图结构的信息损失;LP<sup>[20]</sup>采用高斯随机场和谐波函数进行半监督学习,进行手工提取特征;GCN 采用邻域聚集方案来提高性能,它混合了节点及其邻近点的特征,由于 GCN 模型较浅无法获取全局信息,导致提取特征有限;GRNN 在每一层的传播增加特征矩阵的输入,捕获了多种类型的扩散,同样无法解决 GCN 的限制。

2.3 训练样本点数对结果准确性影响

为了比较对偶图递归神经网络与 GCN、GRNN、LP 网络在少量数据标记的情况下训练结果准确度的对比,在 Cora 数据集上分别取训练标记总数的 1%、2%、3%、4%、5% 来进行测试,验证集和测试集保持不变。由图 4 可以明显地看出在训练标记较少的情况下,本文设计的网络精确度比其他方法精确度更高。这验证了本文网络模型在进行训练时能有效地将标签数据传播到整个图上,在实际生活中能大大缩减标记成本同时提高运行效率。




图 4 训练样本数精度

2.4 网络设计分析

深度池化对偶神经网络主要是通过图池化和随机游走协同训练,来获取图结构数据的深层次语义信息,现对不同的网络层数做对比,如图 5 所示,可以看出框架的有效性。图中:DPDNN 为本文设计的深度池化

对偶神经网络,使用图卷积和随机游走协同训练;DPDNN-1 指去掉所有的粗化操作和细化操作,并将性能与本文设计的性能进行对比,保留了对称残差的连接;DPDNN-2 只是增加图池化进行训练,没有使用随机游走网络进行协同训练。除此之外,还对图池化层数进行了分析,对原始框架中的图池化层数分别设置为 1、2、3、4、5、6、7、8,得到如图 6 所示的分类效果,可以看到当图池化层数为 4 的时候,分类效果最好。

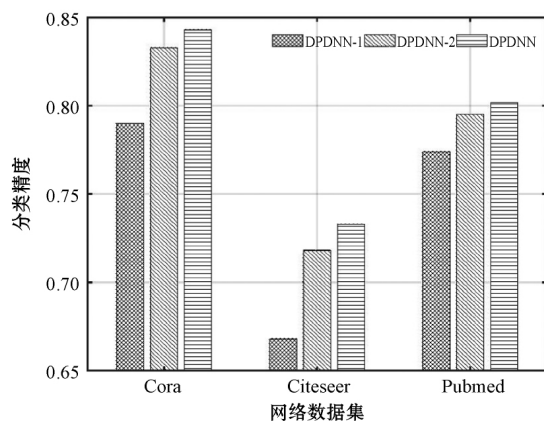


图5 网络框架对比




图6 图池化层数分析

### 3 结 语

本研究设计出深度池化对偶神经网络,在复杂网络中的节点分类取得了较好的结果,所提出的框架由池化层和对称细化层组成,将相似的节点与超节点进行分组可以获得更大的接收域。此外,通过随机游走的方式得到逐点互信息矩阵进行协同训练,与其他先前的工作相比,能充分地利用局部和全局信息得到更好的分类效果。实验结果证明了本文方法解决分类任务的有效性,特别是在标签数据极为匮乏的情况下能够取得实质性的收益。未来工作需要进一步提高大规模数据的计算效率。

### 参 考 文 献

- [1] Fu T, Wu X H. Multi-scale feature based convolutional neural networks for large vocabulary speech recognition [C]//2017 IEEE International Conference on Multimedia and Expo (ICME). IEEE 2017: 1093 - 1098.
- [2] Wang W, Gang J X. Application of convolutional neural network in natural language processing [C]//2018 International Conference on Information Systems and Computer Aided Education (ICISCAE). IEEE 2018: 64 - 70.
- [3] Gori M, Monfardini G, Scarselli F. A new model for learning in graph domains [C]//2005 IEEE International Joint Conference on Neural Networks. IEEE 2005: 729 - 734.
- [4] Scarselli F, Gori M, Tsoi A C, et al. The graph neural network model [J]. IEEE Transactions on Neural Networks 2009, 20(1): 61 - 80.
- [5] Li Y, Tarlow D, Brockschmidt M, et al. Gated graph sequence neural networks [EB]. arXiv: 1511.05493v4 2015.
- [6] Sukhbaatar S, Szlam A, Fergus R. Learning multiagent communication with backpropagation [EB]. arXiv: 1605.07736, 2016.
- [7] Bruna J, Zaremba W, Szlam A, et al. Spectral networks and locally connected networks on graphs [EB]. arXiv: 1312.6203v3 2013.
- [8] Defferrard M, Bresson X, Vandergheynst P. Convolutional neural networks on graphs with fast localized spectral filtering [C]//Proceedings of the 30th International Conference on Neural Information Processing Systems. Curran Associates Inc. 2016: 3844 - 3852.
- [9] Kipf T N, Welling M. Semi-supervised classification with graph convolutional networks [EB]. arXiv: 1609.02907v4, 2016.
- [10] Perozzi B, Al-Rfou R, Skiena S. Deepwalk: Online learning of social representations [C]//Proceedings of the 20th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. ACM 2014: 701 - 710.
- [11] Grover A, Leskovec J. node2vec: Scalable feature learning for networks [C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. ACM 2016: 855 - 864.
- [12] Xu K Y L, Li C T, Tian Y L, et al. Representation learning on graphs with jumping knowledge networks [C]//Proceedings of the 35th International Conference on Machine Learning 2018: 5453 - 5462.
- [13] Ying R, You J X, Morris C, et al. Hierarchical graph representation learning with differentiable pooling [C]//Proceedings of the 32nd International Conference on Neural Information Processing Systems. Curran Associates Inc. 2018: 4805 - 4815.
- [14] Ioannidis V N, Marques A G, Giannakis G B. A recurrent graph neural network for multi-relational data [EB]. arXiv: 1811.02061 2018.

(下转第 163 页)

实验结果表明 SVM 网络对于微弱、啁啾、饱和、非对称光谱的识别效率达到了 100% ,对于正常光谱的识别正确率达到 99.5% ,五种光谱的总识别准确率达到 99.9% ,其中光谱类型识别错误出现在正常光谱数据中,将正常的光谱识别为微弱光谱。因此可以证明 SVM 网络对 FBG 反射光谱类型的识别是有效的。

### 3 结 语

本文研究了基于 SVM 网络的 FBG 反射光谱类型识别方法。结合反射光谱的特征分析,将光谱中的峰值、波峰数量、峰值宽度、对称度作为表征光谱类型的特征进行提取。为提高光纤光栅反射光谱类型识别的准确率,采用交叉验证法对 SVM 网络核函数进行优化,并比较了相同参数下不同核函数的识别准确率。结果表明,采用参数  $c=5.6$ 、 $\gamma=2.22$  的 poly 核函数识别效果最好,识别准确率达到 99.9%。因此,基于 SVM 的光纤光栅反射光谱类型识别方法适合光纤光栅反射光谱类型识别,可以为提高光纤光栅传感网络的可靠性方法研究提供参考。

### 参 考 文 献

- [1] Kawasaki B S, Hill K O, Johnson D C, et al. Narrow-band Bragg reflectors in optical fibers[J]. Optics Letters, 1978, 3(2): 66–68.
- [2] 刘铁根, 王双, 江俊峰, 等. 航空航天光纤传感技术研究进展[J]. 仪器仪表学报, 2014, 35(8): 1681–1692.
- [3] 赛耀樟, 姜明顺, 隋青美, 等. 基于 FBG 传感网络和时间反转聚焦成像方法的声发射定位技术研究[J]. 中国激光, 2014, 41(8): 133–138.
- [4] Ye X W, Su Y H, Xi P S. Statistical analysis of stress signals from bridge monitoring by FBG system[J]. Sensors, 2018, 18(2): 491–505.
- [5] Qiao X, Shao Z, Bao W, et al. Fiber bragg grating sensors for the oil industry[J]. Sensors, 2017, 17(3): 429.
- [6] 马洒洒, 王彬, 李川, 等. 基于 FBG 应变传感器的隧道安全实时监测算法研究[J]. 仪器仪表学报, 2017, 38(2): 304–311.
- [7] Wang K, Zhang S, Chen J, et al. A laboratory experimental study: An FBG-PVC tube integrated device for monitoring the slip surface of landslides[J]. Sensors, 2017, 17(11): 2486–2499.
- [8] Mohammed A, Djurovic S. FBG thermal sensing features for hot spot monitoring in random wound electric machine coils[J]. IEEE Sensors Journal, 2017, 17(10): 3058–3067.
- [9] Raffaella D S. Fiber optic sensors for structural health monitoring of aircraft composite structures: Recent advances and applications[J]. Sensors, 2015, 15(8): 18666–18713.
- [10] Rezayat A, Pauw B D, Lamberti A, et al. Reconstruction of impacts on a composite plate using fiber Bragg gratings(FBG) and inverse methods[J]. Composite Structures, 2016, 149: 1–10.
- [11] 罗彬彬, 赵明富, 石胜辉, 等. 基于星形金纳米颗粒修饰的 81°倾斜光纤光栅生物传感器[J]. 半导体光电, 2018, 39(5): 634–639.
- [12] 冯翔宇. 光纤光栅啁啾效应及不同温度场管结构状态监测技术研究[D]. 南京: 南京航空航天大学, 2017.
- [13] 张娅玲. 光纤光栅应变传感系统性能蜕化特性研究[D]. 重庆: 重庆大学, 2009.
- [14] Liu J, Osadchy M, Ashton L, et al. Deep convolutional neural networks for Raman spectrum recognition: A unified solution[J]. Analyst, 2017, 142(21): 4067–4074.
- [15] 刘俊秀, 杜彬, 邓玉强, 等. 基于差分-主成分分析-支持向量机的有机化合物太赫兹吸收光谱识别方法[J]. 中国激光, 2019, 46(6): 336–343.
- [16] 李四海, 余晓晖. 基于栈式自编码器的 FTIR 光谱识别[J]. 计算机应用与软件, 2018, 35(6): 254–258.
- [17] 高斌, 赵鹏飞, 卢昱欣, 等. 基于 BP 神经网络的血液荧光光谱识别分类研究[J]. 光谱学与光谱分析, 2018, 38(10): 3136–3143.
- [18] Lewis E, Jinesh M, Macpherson W N, et al. Stainless steel component with compressed fiber Bragg grating for high temperature sensing applications[C]//Sixth European Workshop on Optical Fibre Sensors, 2016.
- [19] 李鑫星, 朱晨光, 白雪冰, 等. 基于可见光谱和支持向量机的黄瓜叶部病害识别方法研究[J]. 光谱学与光谱分析, 2019, 39(7): 2250–2256.

(上接第 158 页)

- [15] Li Q M, Han Z C, Wu X M. Deeper insights into graph convolutional networks for semi-supervised learning[C]//Proceedings of the 32nd AAAI Conference on Artificial Intelligence. AAAI Press, 2018: 3538–3545.
- [16] Jiang B, Zhang Z Y, Tang J, et al. Graph optimized convolutional networks[EB]. arXiv: 1904.11883, 2019.
- [17] Sammut C, Webb G I. Encyclopedia of machine learning and data mining[M]. Springer, 2017.
- [18] Levy O, Goldberg Y. Neural word embedding as implicit matrix factorization[C]//Annual Conference on Neural Information Processing Systems, 2014: 2177–2185.
- [19] Yang Z L, Cohen W W, Salakhutdinov R. Revisiting semi-supervised learning with graph embeddings[C]//Proceedings of the 33rd International Conference on Machine Learning. JMLR, 2016: 40–48.
- [20] Zhu X J, Ghahramani Z, Lafferty J D. Semi-supervised learning using gaussian fields and harmonic functions[C]//Proceedings of the 20th International Conference on Machine Learning. AAAI Press, 2003: 912–919.